



AI Lab
STEIITB



Dokumen Jawaban Task #3

Seleksi Laboratorium Intelegensi Buatan

Beyond the Archetype

What we see is not always what the model learns.

Disusun oleh Riantama Putra (18224061)



Daftar Isi

Daftar Isi.....	2
Pengantar.....	3
Skyfall: Persepsi terhadap Machine Learning.....	4
Vesper: Machine Learning di Dunia Nyata.....	10
Spectre: Pengembangan Diri dan Tanggung Jawab.....	17
Referensi.....	24



Pengantar

Machine learning sering dipandang sebagai persoalan memilih model, melatihnya menggunakan data, lalu mengejar nilai evaluasi setinggi mungkin. Semakin jauh saya mempelajari dan menerapkannya, semakin saya menyadari bahwa kualitas sebuah sistem AI tidak hanya ditentukan oleh kinerja model. Perumusan masalah, pemahaman data, penetapan asumsi, evaluasi kegagalan, serta pertanggungjawaban atas keputusan sistem sama pentingnya dengan pemilihan algoritma atau arsitektur.

Dokumen ini memuat tiga refleksi mengenai cara saya memahami *machine learning* dan AI serta arah perkembangan yang ingin saya tempuh. **Skyfall** membahas ketertarikan dan perubahan cara pandang saya terhadap AI. **Vesper** berfokus pada penerapan *machine learning* dalam produk nyata, termasuk pertimbangan di luar performa model. **Spectre** membahas kemampuan yang ingin saya kembangkan, keterbatasan yang masih saya miliki, serta tanggung jawab yang menurut saya melekat pada seorang *engineer* atau *researcher* ketika membangun sistem AI untuk orang lain.

Berbeda dengan aspek teknis Task #3 yang didokumentasikan melalui *notebook*, tulisan ini berfokus pada alasan di balik cara saya berpikir dan mengambil keputusan. Tujuannya bukan untuk menunjukkan bahwa saya telah memiliki seluruh jawaban, melainkan menggambarkan posisi saya saat ini secara jujur: hal yang sudah saya pahami, hal yang masih ingin saya pelajari, serta prinsip yang mulai saya pegang ketika bekerja dengan AI.

Skyfall: Persepsi terhadap Machine Learning

Ketertarikan saya terhadap AI tidak bermula dari keinginan mengikuti satu tren tertentu. Saya justru mulai mengenalnya melalui permasalahan yang konkret, kemudian semakin tertarik ketika menyadari bahwa setiap area AI dapat memiliki cara kerja, kegagalan, dan kebutuhan solusi yang berbeda. Saat ini, dua area yang paling menarik perhatian saya adalah **Computer Vision** dan **Natural Language Processing (NLP)**. *Computer Vision* menjadi pintu masuk saya ke *machine learning*, sedangkan NLP membuat saya semakin penasaran terhadap bagaimana mesin merepresentasikan informasi dan berinteraksi dengan manusia melalui bahasa.

Area yang Paling Saya Minati

Computer Vision merupakan area *machine learning* pertama yang saya pelajari secara cukup serius. Ketertarikan saya bertahan karena istilah “memahami gambar” ternyata mencakup permasalahan yang sangat luas, mulai dari klasifikasi citra, *object detection*, segmentasi, OCR, hingga membedakan karakteristik visual yang sangat halus.

Pengalaman mengerjakan beberapa permasalahan *Computer Vision* membuat saya menyadari bahwa model yang baik tidak cukup hanya memiliki arsitektur besar. Pada permasalahan *face anti-spoofing*, misalnya, saya pernah menghadapi kesalahan klasifikasi antara foto cetak dan tampilan digital. Setelah melakukan *debugging*, salah satu sinyal yang ternyata penting adalah pola frekuensi tinggi dan karakteristik tekstur media cetak yang tidak selalu tertangkap dengan baik oleh *backbone* CNN biasa. Pengalaman lain pada klasifikasi material limbah dan OCR juga menunjukkan bahwa dua masalah yang sama-sama menggunakan gambar belum tentu membutuhkan pendekatan yang sama.

Saya juga menyukai sisi rekayasanya. Melatih model visual membuat saya berhadapan langsung dengan keterbatasan GPU, ukuran *batch*, resolusi citra, waktu pelatihan, dan keputusan apakah sebuah *backbone* perlu dilatih penuh atau cukup dibekukan. Bagi saya, *Computer Vision* menarik karena memadukan pemahaman data, desain model, dan kompromi komputasional.

Sementara itu, ketertarikan saya terhadap NLP muncul dari pertanyaan yang berbeda. Saya cukup sering menggunakan LLM, tetapi semakin sering menggunakannya, semakin saya ingin memahami apa yang terjadi di balik antarmuka percakapan yang terlihat sederhana. Bagaimana sebuah kalimat diubah

menjadi representasi numerik? Bagaimana model mempertahankan konteks yang panjang? Mengapa perubahan kecil pada konteks atau *prompt* dapat menghasilkan jawaban yang berbeda? Daya tarik NLP bagi saya justru berada pada kesenjangan antara keluaran yang terlihat sangat manusiawi dan proses matematis yang berlangsung di bawahnya.

Bagaimana Ketertarikan Itu Terbentuk

Computer Vision menarik bagi saya sejak awal karena hasilnya mudah diamati. Ketika model salah mengklasifikasikan sebuah gambar, saya dapat kembali melihat gambarnya dan bertanya, “Apa yang terlihat jelas bagi manusia tetapi tidak ditangkap model?” Pertanyaan tersebut terus muncul pada berbagai proyek yang saya kerjakan.

Semakin banyak eksperimen yang saya lakukan, semakin saya memahami bahwa keberhasilan model tidak hanya bergantung pada arsitektur. *Preprocessing*, kualitas label, *data leakage*, ketidakseimbangan kelas, skema validasi, dan representasi fitur dapat mengubah hasil secara signifikan. Hal itu membuat saya terus belajar karena ketika sebuah model gagal, hampir selalu ada lapisan lain yang dapat dianalisis selain sekadar mengganti arsitektur.

NLP datang kemudian. Salah satu pemicunya adalah perkembangan LLM dan *coding agent*. Awalnya saya menggunakannya sebagai alat bantu, tetapi penggunaan sehari-hari membuat saya semakin tertarik pada pertanyaan yang lebih mendasar: mengapa model dapat mengikuti instruksi abstrak, menulis kode, menggunakan alat, dan mempertahankan konteks pekerjaan yang cukup panjang?

Analisis Anthropic terhadap sekitar 400.000 sesi Claude Code menunjukkan bahwa manusia masih banyak menentukan **apa** yang perlu dilakukan, sedangkan agen semakin banyak mengambil keputusan mengenai **bagaimana** pekerjaan tersebut dilaksanakan. Analisis yang sama juga menunjukkan bahwa keahlian pengguna tetap berhubungan dengan keberhasilan penggunaan agen [1]. Bagi saya, pola ini lebih menarik daripada narasi sederhana bahwa “AI akan menggantikan programmer”. Pertanyaan yang lebih relevan adalah bagaimana pembagian kerja manusia dan AI akan berubah.

Hal yang Masih Membuat Saya Penasaran

Pada *Computer Vision*, pertanyaan yang paling membuat saya penasaran adalah **seberapa dekat persepsi mesin dapat mendekati cara manusia memahami dunia**

visual. Manusia tidak melihat gambar sebagai kumpulan piksel yang terisolasi. Kita membawa konteks, pengalaman, pengetahuan tentang objek, hubungan spasial, dan ekspektasi terhadap dunia. Karena itu, saya tertarik pada model multimodal dan *vision-language model* yang mencoba menghubungkan persepsi visual dengan representasi semantik. Saya ingin memahami apakah peningkatan model visual ke depan akan lebih banyak berasal dari arsitektur visual yang semakin baik atau justru dari kemampuan menggabungkan citra dengan bahasa, memori, dan pengetahuan dunia.

Pada NLP, salah satu pertanyaan yang paling menarik bagi saya adalah **pengaruh bahasa dan ragam bahasa terhadap kemampuan model**. LORAXBENCH menunjukkan bahwa kemampuan model masih memiliki kesenjangan antara bahasa Indonesia dan berbagai bahasa daerah Indonesia, serta dapat berubah ketika ragam bahasa yang digunakan berubah [2]. Hal ini membuat saya ingin memahami lebih jauh bagaimana model dapat bekerja secara konsisten pada bahasa yang memiliki data jauh lebih sedikit dibandingkan bahasa Inggris.

Saya juga tertarik pada desain *prompt* dan pengelolaan konteks. Saya tidak lagi menganggap bahwa semakin panjang *prompt*, semakin baik jawabannya. Penelitian *Lost in the Middle* menunjukkan bahwa model dengan jendela konteks panjang tetap dapat mengalami penurunan performa ketika informasi penting berada di bagian tengah konteks [3]. Karena itu, pertanyaan yang menurut saya lebih menarik bukan “bagaimana membuat konteks sepanjang mungkin”, melainkan **berapa banyak konteks yang benar-benar dibutuhkan, bagaimana menempatkan informasi penting, dan bagaimana sistem mempertahankan memori tanpa memenuhi konteks dengan informasi yang sudah tidak relevan**.

Pada akhirnya, hal yang paling membuat saya penasaran adalah bagaimana AI dapat menjadi perpanjangan dari alur kerja manusia tanpa membuat manusia kehilangan kendali atas proses berpikirnya sendiri.

Perubahan Cara Pandang dalam Dua Tahun Terakhir

Perubahan terbesar dalam cara pandang saya selama dua tahun terakhir adalah pergeseran dari melihat AI sebagai **alat prediksi** menjadi melihat AI sebagai **sistem yang dapat mengerjakan rangkaian pekerjaan**.

Ketika pertama kali mempelajari *machine learning*, gambaran saya cukup sederhana: tersedia data, model dilatih, lalu model menghasilkan prediksi. Semakin banyak proyek yang saya kerjakan, saya mulai memahami persoalan validasi,

distribusi data, generalisasi, dan keterbatasan metrik. Perkembangan LLM dan *agentic AI* kemudian memperluas gambaran tersebut. Model tidak lagi hanya menghasilkan satu prediksi, tetapi dapat membaca dokumentasi, menulis kode, menjalankan alat, memeriksa hasil, memperbaiki kesalahan, dan melanjutkan pekerjaan berdasarkan hasil sebelumnya.

Saya sempat berpikir bahwa perkembangan tersebut hampir berarti manusia dapat sepenuhnya digantikan pada pekerjaan seperti pemrograman. Sekarang pandangan saya lebih hati-hati. Eksperimen METR terhadap pengembang *open-source* berpengalaman pada awal 2025 justru menemukan bahwa, dalam konteks penelitian tersebut, mereka membutuhkan waktu sekitar 19% lebih lama ketika menggunakan alat AI [4]. Di sisi lain, data penggunaan agen yang lebih baru menunjukkan bahwa durasi pekerjaan yang dapat ditangani agen terus meningkat [5]. Bagi saya, dua hal tersebut menunjukkan bahwa kemampuan AI memang berkembang cepat, tetapi manfaat nyata tetap bergantung pada jenis pekerjaan, kualitas alat, dan kemampuan manusia menggunakannya.

Karena itu, saya sekarang melihat AI bukan sebagai tombol yang otomatis meningkatkan produktivitas, melainkan sebagai **alat yang memiliki kurva keterampilan penggunaannya sendiri**. Risiko yang saya lihat bukan hanya tertinggal karena tidak menggunakan AI, tetapi juga terlalu bergantung pada AI sampai kemampuan untuk memeriksa, mempertanyakan, dan memperbaiki hasilnya ikut menurun.

Perkembangan AI dalam 3–5 Tahun ke Depan

Saya memperkirakan perkembangan terbesar dalam 3–5 tahun ke depan bukan hanya model yang semakin pintar, tetapi **AI yang semakin terhubung dengan dunia di luar kotak percakapan**.

Perubahan tersebut sudah terlihat melalui *agentic AI*. Model mulai dapat menggunakan komputer, memanggil API, mengoperasikan alat, dan menyelesaikan pekerjaan dalam banyak langkah. Tahap berikutnya yang menurut saya menarik adalah ketika kemampuan tersebut semakin terhubung dengan dunia fisik melalui robotika.

Gemini Robotics, misalnya, memperlihatkan arah menuju *vision-language-action model* yang menghubungkan pemahaman visual dan bahasa dengan tindakan robot [6]. Menurut saya, batas antara *Computer Vision*, NLP, robotika, dan *agentic AI* akan semakin kabur. Sistem yang paling menarik mungkin bukan model dengan

kemampuan tertinggi pada satu modalitas, melainkan sistem yang mampu menggabungkan banyak modalitas, menggunakan alat, mempertahankan memori, serta bekerja dalam jangka waktu yang lebih panjang.

Tantangannya juga ikut berubah. Ketika kesalahan model hanya menghasilkan teks yang salah, dampaknya berbeda dengan ketika model dapat mengubah basis data, menjalankan kode, melakukan transaksi, atau menggerakkan robot. Karena itu, menurut saya perkembangan kemampuan dan perkembangan keandalan harus bergerak bersama.

Teknologi yang Terlalu Banyak dan Kurang Mendapat Perhatian

Menurut saya, **generation gambar dan video** memperoleh perhatian publik yang tidak proporsional dibandingkan beberapa area AI lainnya. Saya memahami alasannya karena kemajuannya sangat mudah diperlihatkan. Namun, bagi saya, semakin realistis sebuah video yang dihasilkan bukan perkembangan yang paling menarik dibandingkan kemampuan AI dalam membantu manusia menyelesaikan masalah yang sebelumnya sulit.

Salah satu area yang menurut saya justru kurang mendapat perhatian masyarakat umum adalah **AI dalam kesehatan dan kedokteran**. Yang menarik bagi saya bukan narasi bahwa AI akan menggantikan dokter, melainkan bagaimana AI dapat membantu dokter mengambil keputusan yang lebih baik.

Sebuah uji acak terhadap 50 dokter menemukan bahwa memberikan akses GPT-4 tidak secara signifikan meningkatkan skor penalaran diagnostik dibandingkan penggunaan sumber konvensional, meskipun GPT-4 yang diuji secara mandiri memperoleh skor lebih tinggi dalam eksperimen tersebut [7]. Penelitian lain di Pakistan menunjukkan hasil yang berbeda setelah dokter terlebih dahulu mendapatkan pelatihan literasi AI; bantuan LLM kemudian meningkatkan performa penalaran diagnostik secara berarti [8].

Bagi saya, kedua hasil tersebut jauh lebih menarik daripada kesimpulan sederhana bahwa “AI lebih pintar daripada dokter”. Potensi sebenarnya berada pada pertanyaan: **bagaimana manusia dan AI harus bekerja bersama agar kemampuan keduanya saling melengkapi?**

Satu Keyakinan tentang AI yang Berubah

Dulu saya memiliki pandangan yang cukup sederhana bahwa AI pada akhirnya tetap hanya “alat”. Karena tidak mempunyai niat seperti manusia, saya menganggap cerita mengenai AI yang melakukan tindakan tidak terduga seperti dalam film fiksi ilmiah terlalu jauh untuk menjadi persoalan nyata dalam waktu dekat.

Pandangan tersebut berubah. Saya tetap tidak menganggap AI “jahat” atau memiliki niat manusiawi. Namun, saya sekarang memahami bahwa **sebuah sistem tidak perlu memiliki niat jahat untuk menghasilkan perilaku yang berbahaya**. Model hanya perlu memiliki kemampuan yang cukup tinggi, tujuan yang salah dirumuskan, akses terhadap alat, dan pengamanan yang tidak memadai.

Insiden keamanan yang dilaporkan OpenAI bersama Hugging Face pada 2026 menjadi salah satu contoh yang memperkuat perubahan pandangan saya. Dalam evaluasi kemampuan keamanan siber dengan pengamanan yang sengaja dikurangi, sejumlah model menemukan celah *zero-day* untuk memperoleh akses internet, kemudian mengeksploitasi infrastruktur Hugging Face ketika berusaha menyelesaikan evaluasi [9]. Bagi saya, bagian penting dari kasus tersebut bukan bahwa model “memiliki niat menyerang”, melainkan bahwa rangkaian tindakan yang tidak diinginkan manusia dapat muncul sebagai konsekuensi dari mengejar tujuan yang diberikan.

Hal lain yang mengubah cara pandang saya adalah risiko ketergantungan manusia terhadap AI. Studi awal MIT Media Lab mengenai penggunaan LLM dalam penulisan esai menemukan perbedaan keterlibatan neural, kemampuan mengingat, dan rasa kepemilikan terhadap tulisan antara kelompok pengguna LLM dan kelompok lain [10]. Penelitian tersebut masih berupa *preprint* dan konteksnya terbatas, sehingga saya tidak melihatnya sebagai bukti bahwa AI “menurunkan kecerdasan”. Namun, hasil tersebut cukup untuk membuat risiko *cognitive offloading* berlebihan layak diperhatikan.

Karena itu, keyakinan saya berubah dari **“semakin mampu AI, semakin mampu pula manusia yang menggunakannya”** menjadi **“AI dapat memperbesar kemampuan manusia, tetapi hanya jika manusia tetap mempertahankan kemampuan untuk berpikir, memverifikasi, dan menentukan arah penggunaannya sendiri.”**

Vesper: Machine Learning di Dunia Nyata

Pengalaman saya dengan *machine learning* sejauh ini lebih banyak berasal dari proyek, kompetisi, dan pengembangan prototipe daripada mengoperasikan sistem AI berskala besar di lingkungan produksi. Karena itu, untuk beberapa persoalan produksi, pandangan saya masih berupa *educated estimation* yang dibangun dari pengalaman tersebut dan dari praktik yang digunakan di industri. Namun, berbagai eksperimen yang saya lakukan sudah cukup membuat saya melihat bahwa membuat model dengan nilai evaluasi tinggi hanyalah satu bagian dari membangun sistem AI yang benar-benar berguna.

Hal yang Paling Sering Diremehkan ketika AI Dibawa ke Produksi

Menurut saya, hal yang paling sering diremehkan adalah **segala sesuatu di sekitar model**.

Ketika membangun model, perhatian mudah terpusat pada arsitektur, jumlah parameter, atau nilai pada tolok ukur. Saya sendiri sebelumnya cenderung berpikir bahwa model dari perusahaan besar atau model dengan parameter lebih banyak hampir selalu menjadi pilihan yang lebih baik. Sekarang saya melihat bahwa ukuran dan asal model tidak cukup untuk menentukan apakah model tersebut cocok digunakan dalam produk. Phi-3-mini, misalnya, hanya memiliki sekitar 3,8 miliar parameter tetapi dirancang agar tetap kompetitif pada sejumlah evaluasi sekaligus cukup kecil untuk dijalankan pada perangkat terbatas [11]. Bagi saya, contoh seperti ini menunjukkan bahwa model yang lebih kecil dapat menjadi pilihan lebih baik apabila lebih cepat, lebih murah, dan sudah cukup akurat untuk kebutuhan pengguna.

Begitu model masuk ke produksi, masalah juga tidak berhenti ketika `model.predict()` berhasil dijalankan. Kita perlu memikirkan kualitas input, perubahan distribusi data, kegagalan infrastruktur, biaya inferensi, latensi, keamanan, mekanisme *fallback*, dan cara mengetahui bahwa kualitas model mulai menurun. NIST menempatkan pemantauan setelah penerapan sebagai bagian penting karena perilaku sistem di kondisi nyata dapat berbeda dari evaluasi yang terkontrol [12].

Karena itu, menurut saya model terbaik untuk produksi bukan selalu model dengan skor tertinggi, melainkan **model yang memberikan nilai terbaik sebagai bagian dari sistem yang dapat diandalkan**.

Mengubah Permasalahan Bisnis Menjadi Solusi Berbasis AI

Hal pertama yang saya cari bukan “di bagian mana AI dapat dipasang?”, melainkan **di bagian mana proses saat ini memiliki masalah yang terukur.**

Pekerjaan repetitif memang menjadi salah satu sinyal. Contohnya, proses parkir dapat memiliki pekerjaan berulang seperti membaca pelat nomor, mengidentifikasi kendaraan, atau memantau ketersediaan tempat. Namun, saya tidak lagi berpikir bahwa setiap pekerjaan repetitif otomatis membutuhkan AI. Jika palang hanya perlu terbuka ketika kartu yang valid ditempelkan, aturan deterministik biasa sudah cukup. Menambahkan model *machine learning* justru menambah biaya dan sumber kegagalan yang tidak diperlukan.

Karena itu, saya akan memulai dari pertanyaan: apa masalah yang terjadi, seberapa sering masalah tersebut muncul, apa dampaknya, apakah tersedia data yang merepresentasikan masalah tersebut, dan apakah pola yang ingin dipelajari memang terlalu kompleks untuk diselesaikan dengan aturan biasa? Prinsip ini sejalan dengan *Rules of Machine Learning* dari Google yang menyarankan penggunaan pendekatan sederhana terlebih dahulu ketika heuristik sudah memadai [13].

Setelah itu, saya akan menentukan ukuran keberhasilan sebelum memilih model. Jika masalahnya adalah antrean parkir akibat verifikasi kendaraan yang lambat, tujuan sebenarnya bukan sekadar mencapai akurasi OCR 99%, melainkan **mengurangi waktu antrean tanpa meningkatkan jumlah kendaraan yang salah diizinkan masuk.**

Bagi saya, AI seharusnya datang **setelah masalah dipahami**, bukan menjadi teknologi yang dicari-cari masalahnya.

Kapan Sebuah Masalah Sebaiknya Tidak Diselesaikan dengan AI?

Menurut saya, sebuah masalah sebaiknya tidak dipaksakan menggunakan AI ketika **solusi deterministik yang lebih sederhana sudah dapat memenuhi kebutuhan.** Saya juga akan berhati-hati ketika data terlalu sedikit atau tidak representatif, target keberhasilan tidak dapat didefinisikan dengan jelas, biaya kesalahan jauh lebih besar daripada manfaat otomatisasi, atau sistem tidak memiliki mekanisme ketika model ragu atau gagal.

Saya sebelumnya berpikir bahwa area seperti medis sebaiknya sama sekali tidak menggunakan AI karena berhubungan langsung dengan nyawa manusia. Pandangan saya sekarang lebih bernuansa. FDA telah mengevaluasi berbagai perangkat medis berbasis AI, yang menunjukkan bahwa AI dapat memiliki peran nyata dalam kesehatan ketika dikembangkan dan dievaluasi secara tepat [14].

Yang tidak saya setuju adalah **menyerahkan keputusan berisiko tinggi sepenuhnya kepada model hanya karena nilai evaluasinya tinggi**. Semakin besar konsekuensi kesalahan, semakin tinggi kebutuhan terhadap validasi, pengawasan manusia, kemampuan melakukan intervensi, dan pemahaman terhadap dasar rekomendasi. Dalam konteks *clinical decision support*, FDA juga menekankan bahwa tenaga kesehatan perlu dapat meninjau dasar rekomendasi dan tetap menggunakan penilaian profesionalnya sendiri [15].

Jadi bagi saya pertanyaannya bukan “bolehkah AI digunakan?”, melainkan **seberapa besar kewenangan yang layak diberikan kepada AI pada tingkat risiko tersebut?**

Menentukan Apakah Sistem AI Benar-Benar Berhasil

Menurut saya, **metrik model diperlukan, tetapi tidak cukup**.

Nilai F1, akurasi, RMSE, atau metrik lainnya menjawab apakah model bekerja dengan baik pada suatu *dataset*. Produk membutuhkan pertanyaan yang lebih besar: **apakah sistem membuat kondisi pengguna atau proses yang ingin diperbaiki menjadi lebih baik?**

Misalnya, model deteksi kendaraan dapat memiliki akurasi tinggi, tetapi sistem belum tentu berhasil apabila inferensinya membutuhkan beberapa detik dan justru memperpanjang antrean. *Chatbot* dapat memperoleh nilai tinggi pada evaluasi jawaban, tetapi belum tentu berhasil apabila pengguna tetap memilih menghubungi manusia karena tidak percaya terhadap jawabannya.

Karena itu, saya akan melihat beberapa lapisan metrik sekaligus:

1. **Metrik model**, seperti F1, *precision*, *recall*, dan kalibrasi.
2. **Metrik sistem**, seperti latensi, ketersediaan layanan, biaya inferensi, dan tingkat kegagalan.
3. **Metrik pengguna atau bisnis**, seperti waktu yang dihemat, pekerjaan manual yang berkurang, tingkat penyelesaian tugas, atau kepuasan pengguna.

4. **Metrik risiko**, seperti *false positive* pada kasus berbahaya, keluhan pengguna, atau frekuensi kebutuhan intervensi manusia.

NIST juga menekankan bahwa sistem AI perlu dipantau dalam kondisi penggunaan sebenarnya, termasuk untuk mendeteksi degradasi performa, pergeseran data, masalah operasional, dan dampak yang tidak diperkirakan [12]. Bagi saya, model dengan F1 0,95 yang tidak memberikan perubahan nyata bukan sistem yang lebih berhasil daripada model F1 0,92 yang benar-benar menyelesaikan masalah pengguna.

Tantangan ketika AI Digunakan Langsung oleh Pengguna

Menurut saya, salah satu masalah tersulit justru bukan berasal dari model, tetapi dari **hubungan antara pengguna dan model**.

Kemampuan pengguna dalam menggunakan AI sangat beragam. Pengguna yang memahami keterbatasan sistem dapat memberikan konteks yang baik, memeriksa hasilnya, dan mengetahui kapan AI perlu dikoreksi. Pengguna lain mungkin memberikan instruksi yang sangat minim, menganggap jawaban AI selalu benar, atau justru tidak mempercayai sistem sama sekali.

Karena itu, produk AI yang baik tidak seharusnya mengharuskan setiap pengguna menjadi ahli *prompt engineering*. Tanggung jawab perancang sistem adalah membuat penggunaan yang benar menjadi mudah melalui antarmuka yang jelas, pilihan tindakan yang terstruktur, contoh input, konfirmasi untuk tindakan berisiko, serta mekanisme untuk memperbaiki atau membatalkan keputusan AI.

Hal ini juga membuat saya melihat bahwa kepercayaan pengguna bukan sesuatu yang harus selalu dimaksimalkan. **Pengguna seharusnya memiliki tingkat kepercayaan yang sesuai dengan kemampuan sistem.** Terlalu sedikit kepercayaan membuat AI tidak digunakan, sedangkan terlalu banyak kepercayaan dapat membuat pengguna menerima kesalahan tanpa verifikasi. Pendekatan *human-centered AI* NIST juga menempatkan interaksi manusia-AI, kepercayaan, dan konteks penggunaan sebagai bagian penting dalam evaluasi sistem [16].

Trade-off antara Akurasi, Biaya, Latency, Reliability, dan Kemudahan Penggunaan

Saya tidak melihat adanya satu urutan prioritas yang berlaku untuk seluruh produk. Prioritasnya harus mengikuti **konteks penggunaan dan konsekuensi kesalahan**.

Untuk aplikasi yang berinteraksi langsung dengan pengguna, latensi dan kemudahan penggunaan dapat menjadi sangat penting. Peningkatan akurasi dari 94% menjadi 95% mungkin tidak terasa apabila konsekuensinya adalah waktu respons meningkat dari satu menjadi sepuluh detik. Sebaliknya, pada sistem yang menjalankan perhitungan penting secara *batch* dan tidak membutuhkan respons langsung, saya lebih rela menerima proses yang lambat apabila memberikan peningkatan akurasi dan keandalan yang berarti.

Pada sistem berisiko tinggi, prioritasnya berubah lagi. Saya mungkin lebih memilih model yang sedikit lebih rendah akurasinya tetapi lebih mudah diaudit, memiliki perilaku kegagalan yang dapat diprediksi, dan memungkinkan manusia melakukan intervensi.

Cara yang menurut saya paling masuk akal adalah menentukan **batas minimum yang tidak boleh dilanggar terlebih dahulu**: tingkat akurasi minimum, latensi maksimum, batas biaya per permintaan, dan mekanisme *fallback* ketika model gagal. Setelah syarat tersebut terpenuhi, barulah kita mengoptimalkan kombinasi metrik lainnya. Dengan cara ini, pemilihan model bukan perlombaan mencari angka evaluasi tertinggi, tetapi persoalan mencari **titik operasi yang paling sesuai dengan kebutuhan sistem**.

Menggunakan Model yang Sulit Dijelaskan

Saya cukup terbuka menggunakan model yang sulit dijelaskan, tetapi tingkat keterbukaan saya **bergantung pada risiko keputusan tersebut**.

Untuk keputusan berisiko rendah dan mudah dibatalkan, saya tidak keberatan menggunakan model *black box* apabila model tersebut memberikan performa jauh lebih baik dan telah diuji dengan baik. Sistem rekomendasi lagu, misalnya, tidak harus dapat menjelaskan setiap parameter yang menyebabkan satu lagu direkomendasikan.

Situasinya berbeda ketika keputusan memengaruhi kesehatan, keuangan, keselamatan, atau kesempatan seseorang. Metode *explainability* seperti SHAP dapat membantu menunjukkan kontribusi fitur terhadap suatu prediksi [17]. Namun, menurut saya penjelasan semacam itu tidak otomatis membuat *black box* sepenuhnya dapat dipercaya. Penjelasan *post hoc* tetap merupakan interpretasi terhadap perilaku model, bukan bukti bahwa kita memahami seluruh mekanisme internal atau hubungan kausal di balik prediksinya.

Karena itu, saya setuju dengan prinsip bahwa semakin tinggi risiko keputusan, semakin besar alasan untuk mempertimbangkan model yang secara intrinsik lebih mudah diinterpretasikan. Cynthia Rudin bahkan berargumen bahwa pada keputusan berisiko tinggi, model yang dapat diinterpretasikan sejak awal sering kali lebih tepat daripada menggunakan *black box* lalu mencoba menjelaskannya setelah keputusan dibuat [18].

Jadi pertanyaan saya bukan sekadar “apakah model ini akurat?”, tetapi juga **siapa yang menanggung konsekuensi ketika model salah dan apakah orang tersebut dapat memahami atau mempertanyakan keputusan yang dibuat?**

Ketika Hasil Model Tidak Sesuai Ekspektasi

Saya cukup sering mengalami kondisi ketika hasil model tidak sesuai ekspektasi. Salah satu contoh paling baru justru terjadi ketika mengerjakan Dere Detector pada Task #3 ini.

Saya beberapa kali menemukan eksperimen yang terlihat lebih baik berdasarkan validasi, tetapi peningkatannya tidak konsisten ketika diuji lebih lanjut atau tidak berhasil mengalahkan model yang lebih sederhana pada *public leaderboard*. Saya juga menemukan bahwa membuat mekanisme pemilihan model, pembobotan, atau koreksi prediksi semakin kompleks tidak otomatis meningkatkan generalisasi.

Pengalaman tersebut mengubah cara saya memandang eksperimen. Sebelumnya saya lebih mudah melihat peningkatan metrik sebagai bukti bahwa pendekatan baru lebih baik. Sekarang saya berusaha bertanya lebih jauh: **apakah peningkatan tersebut berasal dari sinyal baru yang benar-benar berguna atau hanya karena saya semakin menyesuaikan keputusan terhadap satu skema validasi tertentu?**

Dari sana saya belajar tiga hal. Pertama, pertahankan *baseline* yang kuat dan jangan mengubahnya tanpa bukti yang cukup. Kedua, evaluasi tidak boleh hanya melihat satu angka agregat; performa per kelas, per *fold*, dan kasus yang berubah juga perlu diperiksa. Ketiga, eksperimen yang gagal tetap berguna apabila dapat menjelaskan mengapa sebuah hipotesis tidak bekerja.

Pelajaran yang paling penting bagi saya adalah bahwa model tidak perlu “mengerti apa yang saya inginkan”. **Tugas saya sebagai pembuat sistem adalah merumuskan masalah, menyediakan sinyal yang benar, membuat evaluasi yang dapat dipercaya, serta mendesain sistem agar tetap aman ketika model melakukan kesalahan.** Dari situ saya semakin melihat perbedaan antara membuat



model dan membuat produk AI: membuat model berakhir ketika prediksi dihasilkan, sedangkan membuat produk AI baru benar-benar dimulai ketika prediksi tersebut digunakan oleh manusia.

Spectre: Pengembangan Diri dan Tanggung Jawab

Semakin banyak saya mempelajari *machine learning* dan AI, semakin saya menyadari bahwa berkembang di bidang ini tidak cukup hanya dengan mampu melatih model yang memiliki performa tinggi. Saya ingin berkembang menjadi seseorang yang mampu memahami keseluruhan proses, mulai dari merumuskan masalah, membangun model, mengoperasikannya sebagai sebuah sistem, hingga bertanggung jawab terhadap keputusan yang dihasilkan ketika sistem tersebut digunakan oleh orang lain.

Saya juga tidak merasa sudah memiliki kemampuan tersebut secara utuh. Justru saat ini saya mulai lebih memahami bagian mana yang sudah cukup saya kuasai, bagian mana yang masih lemah, serta kebiasaan berpikir apa yang perlu saya perbaiki.

Kemampuan yang Ingin Saya Kembangkan dalam 1–2 Tahun ke Depan

Dalam 1–2 tahun ke depan, kemampuan yang paling ingin saya kembangkan adalah **membangun sistem *machine learning* secara *end-to-end***.

Selama ini, sebagian besar pengalaman saya berpusat pada eksperimen: memahami data, memilih arsitektur, melatih model, melakukan validasi, menganalisis kesalahan, lalu mencoba meningkatkan performanya. Saya cukup terbiasa dengan pertanyaan seperti “model apa yang lebih cocok?” atau “mengapa eksperimen ini gagal?”. Namun, saya ingin bergerak ke pertanyaan yang lebih luas: **bagaimana model tersebut benar-benar menjadi bagian dari sistem yang dapat digunakan dan dipertahankan?**

Artinya, saya ingin lebih memahami *data pipeline*, penyajian model (*model serving*), penerapan, pelacakan eksperimen, pemantauan, pergeseran data, pelatihan ulang, dan cara kembali ke versi model sebelumnya ketika versi baru menimbulkan masalah. Praktik MLOps menempatkan validasi data dan model, otomatisasi *pipeline*, penerapan, pemantauan, dan pelatihan ulang sebagai bagian dari siklus hidup sistem *machine learning*, bukan pekerjaan tambahan setelah model selesai [19].

Saya juga ingin memperdalam **efisiensi model**, bukan hanya mengejar performa. Saya ingin lebih memahami kapan *quantization*, *distillation*, *batching*, pemilihan presisi numerik, atau penggunaan model yang lebih kecil dapat menghasilkan

sistem yang jauh lebih murah tanpa kehilangan kemampuan yang benar-benar dibutuhkan pengguna.

Tujuan saya bukan sekadar menjadi seseorang yang dapat membuat model bekerja, tetapi menjadi **AI/ML engineer yang dapat memahami dan bertanggung jawab terhadap keseluruhan siklus hidup sistem tersebut.**

Bagian Machine Learning yang Masih Menjadi Kelemahan

Dibandingkan *Computer Vision*, saya merasa pengalaman saya pada **NLP dan time series** masih belum cukup dalam.

Saya mulai lebih banyak menyentuh NLP, termasuk melalui Task #3 ini, tetapi pengalaman saya belum sebanyak pada *Computer Vision*. Saya masih ingin memahami dengan lebih kuat bagaimana representasi bahasa bekerja, bagaimana *fine-tuning* mengubah perilaku model, bagaimana mengevaluasi sistem NLP tanpa terlalu bergantung pada satu metrik, dan bagaimana menjaga konsistensi ketika konteks, gaya bahasa, atau domain berubah.

Untuk *time series*, kelemahan saya bahkan lebih mendasar karena jumlah persoalan yang pernah saya kerjakan jauh lebih sedikit. Saya ingin lebih memahami ketergantungan temporal, *seasonality*, perubahan distribusi terhadap waktu, dan cara membuat skema validasi yang tidak secara tidak sengaja membocorkan informasi dari masa depan.

Kelemahan lain yang penting bagi saya adalah **optimisasi biaya dan efisiensi sistem**. Dalam kompetisi, pertanyaan yang sering saya hadapi adalah “bagaimana mendapatkan skor terbaik dengan GPU yang tersedia?”. Dalam produk nyata, pertanyaannya berbeda. Peningkatan performa yang kecil mungkin tidak layak apabila kebutuhan GPU, memori, dan biaya inferensi meningkat berkali-kali lipat. Karena itu, saya ingin belajar melakukan *profiling* secara lebih disiplin dan menilai model bukan hanya dari F1 atau akurasi, tetapi juga dari memori, laju pemrosesan, latensi, biaya per inferensi, dan kompleksitas operasional.

Saya tidak melihat kelemahan tersebut sebagai sesuatu yang perlu disembunyikan. Mengetahui bagian yang belum saya pahami justru memberi saya arah belajar yang lebih jelas.

Pengalaman yang Paling Mengubah Cara Saya Berpikir

Salah satu asumsi yang cukup lama saya miliki adalah bahwa **model yang lebih besar hampir selalu akan menghasilkan solusi yang lebih baik**.

Pengalaman melakukan berbagai eksperimen membuat pandangan tersebut berubah. Saya menemukan bahwa model yang lebih besar atau lebih kuat secara individual tidak otomatis menjadi solusi terbaik. Pada beberapa kondisi, kombinasi beberapa model yang lebih sederhana tetapi memiliki pola kesalahan berbeda justru dapat menghasilkan hasil yang lebih baik.

Dari situ saya mulai memahami bahwa yang penting dalam *ensemble* bukan sekadar berapa banyak model yang digabungkan, melainkan apakah setiap model membawa **informasi yang saling melengkapi**. Pelajaran yang lebih besar sebenarnya bukan tentang *ensemble*, melainkan tentang cara saya melakukan eksperimen.

Sekarang saya berusaha tidak terlalu cepat menyimpulkan bahwa arsitektur yang lebih besar, lebih baru, atau lebih kompleks pasti lebih baik. Saya lebih memilih memulai dari *baseline* yang dapat dipercaya, membangun hipotesis mengenai kelemahannya, kemudian menambahkan kompleksitas hanya ketika ada alasan yang jelas.

Task Dere Detector semakin memperkuat pandangan tersebut. Saya beberapa kali menemukan pendekatan yang memberikan peningkatan pada satu evaluasi, tetapi peningkatan itu tidak selalu bertahan pada evaluasi lain. Saya belajar bahwa **angka yang naik tidak selalu berarti pemahaman kita terhadap masalah juga membaik**. Bagi saya, salah satu bentuk kemajuan dalam belajar *machine learning* justru adalah menjadi lebih sulit diyakinkan oleh hasil eksperimen sendiri.

Risiko AI yang Paling Saya Pikirkan

Risiko AI yang paling sering saya pikirkan saat ini bukan skenario yang paling dramatis, melainkan sesuatu yang sudah mulai terjadi dalam kehidupan sehari-hari: **ketergantungan terhadap AI sampai manusia perlahan berhenti melatih kemampuan berpikirnya sendiri**.

Saya menggunakan AI cukup sering dan melihat manfaatnya sangat besar. Karena itu, saya tidak berpikir solusinya adalah berhenti menggunakan AI. Masalah muncul ketika AI berubah dari alat yang membantu proses berpikir menjadi alat yang **menggantikan proses berpikir**.

Penelitian Microsoft Research bersama peneliti Carnegie Mellon terhadap 319 pekerja pengetahuan menemukan bahwa kepercayaan yang lebih tinggi terhadap GenAI berkaitan dengan kecenderungan lebih rendah untuk melaporkan keterlibatan berpikir kritis dalam tugas yang dibantu AI [20]. Studi awal MIT Media Lab juga menemukan perbedaan keterlibatan neural, kemampuan mengingat, dan rasa kepemilikan terhadap tulisan pada penggunaan LLM [10]. Penelitian MIT tersebut masih berupa *preprint* dan memiliki konteks yang terbatas, sehingga saya tidak melihatnya sebagai bukti bahwa “AI membuat manusia bodoh”. Namun, keduanya membuat risiko ketergantungan layak dipikirkan dengan serius.

Risiko yang saya lihat adalah terciptanya sebuah siklus: karena AI dapat memberikan jawaban dengan cepat, kita semakin jarang mencoba menyelesaikan masalah sendiri; karena semakin jarang berlatih, kemampuan kita menilai apakah jawaban AI masuk akal ikut melemah; akhirnya kita semakin bergantung pada sistem yang semakin sulit kita verifikasi.

Karena itu, prinsip yang ingin saya pegang adalah: **gunakan AI untuk memperbesar kemampuan berpikir, bukan untuk menghindari kebutuhan untuk berpikir.**

Mempertanyakan Penggunaan AI dari Sisi Etika dan Dampaknya

Saya belum pernah terlibat dalam produk AI berskala besar yang membuat saya menghadapi dilema etis dengan konsekuensi serius. Namun, ada persoalan yang lebih dekat dengan keseharian saya yang cukup sering membuat saya mempertanyakan cara AI digunakan, yaitu **penggunaan AI dalam praktikum pemrograman dasar (Algoritma dan Pemrograman & Object Oriented Programming).**

Saya melihat mahasiswa menggunakan AI untuk menyelesaikan praktikum yang sebenarnya dirancang untuk melatih logika pemrograman, pemahaman algoritma, *debugging*, dan kemampuan membaca kesalahan program. Menurut saya, persoalannya bukan sekadar “menggunakan AI berarti curang”. AI dapat menjadi alat belajar yang sangat berguna. Seseorang dapat meminta penjelasan mengapa programnya gagal, meminta contoh konsep yang serupa, atau berdiskusi mengenai alternatif penyelesaian masalah.

Masalah muncul ketika tujuan praktikum berubah dari “saya ingin memahami bagaimana menyelesaikan masalah ini” menjadi “saya hanya perlu membuat program ini lolos penilaian”. Jika seluruh solusi diberikan kepada AI lalu mahasiswa

hanya menyalinnya tanpa memahami prosesnya, nilai praktikum mungkin meningkat, tetapi tujuan pembelajarannya justru gagal.

UNESCO mendorong pendekatan penggunaan AI dalam pendidikan yang berpusat pada manusia, yaitu teknologi digunakan untuk mendukung pembelajaran dan pengembangan kapasitas manusia, bukan sekadar menggantikan aktivitas belajar [21]. Hal tersebut membuat saya lebih berhati-hati terhadap satu pertanyaan ketika menggunakan AI: **apakah AI sedang membantu saya mengerjakan sesuatu yang sudah saya pahami, membantu saya memahami sesuatu yang belum saya pahami, atau justru menyembunyikan fakta bahwa saya belum memahami apa yang saya kerjakan?**

Menurut saya, ketiganya dapat terlihat mirip dari luar, tetapi dampaknya terhadap proses belajar sangat berbeda.

Tanggung Jawab ketika Sistem AI Menghasilkan Keputusan yang Salah

Menurut saya, ketika sistem AI menghasilkan keputusan yang salah, tanggung jawab seorang *engineer* tidak berhenti pada kalimat **“modelnya memang tidak mungkin 100% akurat”**.

Benar bahwa tidak ada sistem yang sempurna. Namun, ketidakpastian tersebut justru harus diperhitungkan sejak sistem dirancang. Tanggung jawab pertama adalah **mengakui dan memahami dampak kesalahan**. Jika kesalahan dapat merugikan pengguna, prioritas pertama bukan meningkatkan skor model, melainkan menghentikan atau membatasi dampaknya. Dalam kondisi tertentu, hal itu dapat berarti kembali ke versi sebelumnya, mengaktifkan *fallback*, meminta intervensi manusia, atau menonaktifkan sementara suatu fitur.

Setelah itu, perlu dilakukan analisis akar masalah: apakah masalah berasal dari data, perubahan distribusi, implementasi, *preprocessing*, model, desain antarmuka, atau asumsi awal yang memang salah? Tahap berikutnya bukan hanya memperbaiki contoh yang gagal, tetapi bertanya: **mengapa sistem kita memungkinkan kegagalan tersebut mencapai pengguna?**

Dari sana, perbaikannya dapat berupa penambahan pengujian, perubahan metrik evaluasi, pemantauan baru, mekanisme peninjauan manusia, perbaikan data, atau perubahan desain sistem. NIST AI Risk Management Framework menempatkan

akuntabilitas, dokumentasi, pemantauan, pembagian tanggung jawab, dan pengelolaan risiko sebagai bagian dari siklus hidup sistem AI [22].

Menurut saya, hal terpenting adalah **tidak menggunakan model sebagai tempat memindahkan tanggung jawab**. Model tidak dapat meminta maaf kepada pengguna, menentukan apakah sebuah risiko dapat diterima, atau bertanggung jawab atas keputusan untuk menerapkan sistem. Manusia yang membangun dan mengoperasikan sistem tersebut tetap harus mengambil tanggung jawab.

Kesalahan juga tidak selalu berarti seseorang harus langsung disalahkan atau dihukum. Dalam tim yang sehat, kesalahan seharusnya menjadi kesempatan untuk memahami kelemahan sistem dan mencegah pengulangan. Namun, menerima bahwa kesalahan dapat terjadi berbeda dengan menerima bahwa kesalahan boleh diabaikan.

Orang seperti Apa yang Ingin Saya Jadi dalam Sebuah Tim

Dalam sebuah tim, saya ingin dikenal sebagai orang yang **dapat memberikan arah tanpa merasa harus selalu menjadi orang yang paling tahu**.

Jika mendapat kesempatan memimpin, saya ingin bertindak sebagai *leader*, bukan sekadar *boss*. Bagi saya, membagi tugas bukan berarti mengatakan kepada orang lain apa yang harus mereka kerjakan lalu menunggu hasilnya. Seorang pemimpin harus memahami tujuan yang ingin dicapai, mengetahui alasan pembagian pekerjaan, membantu ketika anggota tim mengalami hambatan, dan tetap ikut bertanggung jawab terhadap hasil akhir.

Saya ingin menjadi orang yang dapat mengatakan, “Bagian ini kamu kerjakan karena menurut saya kemampuanmu paling cocok di sini. Saya akan mengerjakan bagian ini, kemudian kita evaluasi hasilnya bersama,” bukan sekadar, “Kamu kerjakan ini karena saya yang menyuruh.”

Saya juga ingin menjadi anggota tim yang dapat diajak berpikir bersama. Jika eksperimen gagal, saya ingin ikut mencari penyebabnya. Jika ada keputusan yang menurut saya kurang tepat, saya ingin cukup berani untuk menyampaikan alasannya. Sebaliknya, jika ternyata pendapat saya salah, saya ingin mampu mengakuinya dan mengubah keputusan berdasarkan bukti yang lebih baik.

Secara teknis, kontribusi yang ingin saya bawa adalah sebagai **AI/ML engineer** yang tidak hanya mampu melakukan eksperimen model, tetapi juga membantu



menghubungkan eksperimen tersebut dengan sistem yang benar-benar dapat digunakan. Namun, kontribusi yang lebih penting bagi saya adalah membantu menciptakan kondisi ketika anggota tim dapat bekerja dengan jelas, saling mempertanyakan asumsi, dan tidak takut mengakui bahwa sesuatu belum diketahui.

Pada akhirnya, saya tidak ingin dikenal sebagai orang yang selalu mempunyai jawaban. Saya ingin dikenal sebagai orang yang **ikut turun tangan, dapat dipercaya ketika menghadapi masalah, dan membantu tim menemukan jawaban yang lebih baik bersama-sama.**

Referensi

- [1] Anthropic, “Agentic Coding and Persistent Returns to Expertise,” 2026. Tersedia pada: <https://www.anthropic.com/research/claude-code-expertise>.
- [2] A. F. Aji dan T. Cohn, “LORAXBENCH: A Multitask, Multilingual Benchmark Suite for 20 Indonesian Languages,” dalam *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, 2025, hlm. 17421–17446. doi: 10.18653/v1/2025.emnlp-main.881.
- [3] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, dan P. Liang, “Lost in the Middle: How Language Models Use Long Contexts,” *Transactions of the Association for Computational Linguistics*, vol. 12, hlm. 157–173, 2024.
- [4] J. Becker, N. Rush, B. Barnes, dan D. Rein, “Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity,” *Model Evaluation & Threat Research*, 2025. Tersedia pada: <https://metr.org/blog/2025-07-10-early-2025-ai-experienced-os-dev-study/>.
- [5] Anthropic, “Measuring AI Agent Autonomy in Practice,” 2026. Tersedia pada: <https://www.anthropic.com/research/measuring-agent-autonomy>.
- [6] Google DeepMind, “Gemini Robotics Brings AI into the Physical World,” 2025. Tersedia pada: <https://deepmind.google/blog/gemini-robotics-brings-ai-into-the-physical-world/>.
- [7] E. Goh, R. Gallo, J. Hom, dkk., “Large Language Model Influence on Diagnostic Reasoning: A Randomized Clinical Trial,” *JAMA Network Open*, vol. 7, no. 10, e2440969, 2024. doi: 10.1001/jamanetworkopen.2024.40969.
- [8] I. A. Qazi, A. Ali, A. U. Khawaja, dkk., “Large Language Model Diagnostic Assistance for Physicians in a Lower-Middle-Income Country: A Randomized Controlled Trial,” *Nature Health*, vol. 1, hlm. 198–205, 2026. doi: 10.1038/s44360-025-00007-8.
- [9] OpenAI, “OpenAI and Hugging Face Partner to Address Security Incident During Model Evaluation,” 2026. Tersedia pada: <https://openai.com/index/hugging-face-model-evaluation-security-incident/>.



- [10] N. Kosmyna, E. Hauptmann, Y. T. Yuan, J. Situ, X.-H. Liao, A. V. Beresnitzky, I. Braunstein, dan P. Maes, “Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task,” arXiv:2506.08872, 2025.
- [11] M. Abdin, J. Aneja, H. Awadalla, dkk., “Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone,” arXiv:2404.14219, 2024.
- [12] A. Rao, A. Keller, N. Kalra, R. Steed, K. Kwegyir-Aggrey, K. Klyman, D. Staheli, dan A. Bergman, “Challenges to the Monitoring of Deployed AI Systems,” NIST AI 800-4, National Institute of Standards and Technology, 2026. doi: 10.6028/NIST.AI.800-4.
- [13] Google, “Rules of Machine Learning: Best Practices for ML Engineering.” Tersedia pada: <https://developers.google.com/machine-learning/guides/rules-of-ml>.
- [14] U.S. Food and Drug Administration, “Artificial Intelligence-Enabled Medical Devices,” 2026. Tersedia pada: <https://www.fda.gov/medical-devices/software-medical-device-samd/artificial-intelligence-enabled-medical-devices>.
- [15] U.S. Food and Drug Administration, “Clinical Decision Support Software,” 2026. Tersedia pada: <https://www.fda.gov/medical-devices/digital-health-center-excellence/step-6-software-function-intended-provide-clinical-decision-support>.
- [16] National Institute of Standards and Technology, “Human-Centered AI.” Tersedia pada: <https://www.nist.gov/programs-projects/human-centered-ai>.
- [17] S. M. Lundberg dan S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” dalam *Advances in Neural Information Processing Systems 30*, 2017, hlm. 4765–4774.
- [18] C. Rudin, “Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead,” *Nature Machine Intelligence*, vol. 1, hlm. 206–215, 2019. doi: 10.1038/s42256-019-0048-x.
- [19] Google Cloud, “MLOps: Continuous Delivery and Automation Pipelines in Machine Learning,” 2024. Tersedia pada: <https://docs.cloud.google.com/architecture/mlops-continuous-delivery-and-automation-pipelines-in-machine-learning>.



[20] H.-P. Lee, A. Sarkar, L. Tankelevitch, I. Drosos, S. Rintel, R. Banks, dan N. Wilson, “The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers,” dalam *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, 2025. doi: 10.1145/3706598.3713778.

[21] F. Miao dan W. Holmes, *Guidance for Generative AI in Education and Research*. Paris, Prancis: UNESCO, 2023.

[22] E. Tabassi, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1. Gaithersburg, MD, Amerika Serikat: National Institute of Standards and Technology, 2023. doi: 10.6028/NIST.AI.100-1.